

# SME0822 - Análise Multivariada e Aprendizado Não Supervisionado

Francisco Miranda

November 8, 2022

## Contents

<b>1</b>	<b>Atividade 3 - Francisco Miranda - 4402962</b>	<b>1</b>
1.1	Exercício 2 . . . . .	2
1.2	(b) região de confiança para o vetor de médias . . . . .	2
1.3	(e) Testes de hipótese . . . . .	2
1.4	Exercício 4 . . . . .	3
1.5	Exercício 5.9 . . . . .	5
1.5.1	(a) Intervalos de 95% de confiança simultâneos para as seis medidas . . . . .	5
1.5.2	(c) Intervalos de 95% de confiança de Bonferroni si- multâneos para as seis medidas . . . . .	6

## 1 Atividade 3 - Francisco Miranda - 4402962

```
# bibliotecas utilizadas
library(tidyverse)
library(ggExtra)
library(ascii)
library(multcomp)
options(asciiType = "org")
library(jocre)
library('rockchalk')
library(MVTests)
```

## 1.1 Exercício 2

Carregamos o conjunto de dados que representa uma amostra aleatória de tamanho 42 observada, da qual temos o vetor de médias e a matrix de variância covariância.

```
n <- 42
mu <- c(0.564, 0.603)
S <- matrix(c(0.0144, 0.0117, 0.0117, 0.0146), ncol = 2)
```

## 1.2 (b) região de confiança para o vetor de médias

Encontramos a região de 95% de confiança para  $\mu$  com auxílio da função pacote ‘mvrnorm’

```
data <- mvrnorm(n= n,
               mu=mu,
               Sigma=S
               )
```

```
cset(data, method = "hotelling", alpha = 0.05)
```

Parameter estimates and projected boundaries of the 2-dimensional 95% simultaneous confidence region:

	Estimate	Lower	Upper
[1,]	0.557	0.508	0.606
[2,]	0.595	0.548	0.642

## 1.3 (e) Testes de hipótese

```
test <- OneSampleHT2(data, mu=c(0.6,0.58))
summary(test)
```

One Sample Hotelling T Square Test

Hotelling T Square Statistic = 27.03965

F value = 13.19 , df1 = 2 , df2 = 40 , p-value: 3.99e-05

#### Descriptive Statistics

	[,1]	[,2]
N	42.0000000	42.0000000
Means	0.5572382	0.5952397
Sd	0.1238484	0.1181872

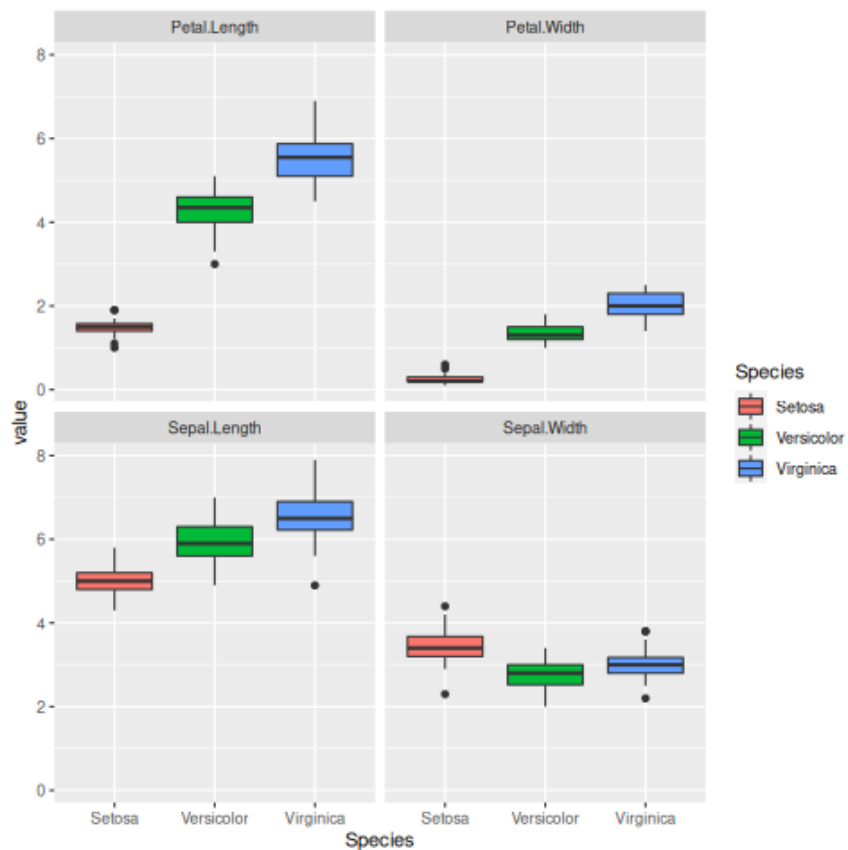
#### Detection important variable(s)

	Lower	Upper	Mu0	Important Variables?
1	0.5080501	0.6064263	0.60	FALSE
2	0.5483000	0.6421794	0.58	FALSE

### 1.4 Exercício 4

Vamos avaliar se há diferença estatisticamente significativa entre as variáveis do conjunto de dados 'iris'. Iniciamos nossa análise observando a distribuições dos tamanhos de sépala e pétala de acordo com a espécie.

```
iris |> pivot_longer(cols = !"Species") |>
  ggplot(aes(x = Species, y = value, fill = Species)) +
  geom_boxplot() +
  facet_wrap(~name)
```



Vamos tentar captar as diferenças significativas entre os três grupos através do teste MANOVA. Nossas hipóteses são:

$h_0$  não existem diferenças significativas entre as médias dos grupos, versus  
 $h_a$ :\* a média de pelo menos um dos grupos é diferente das demais.

```
fit <- manova(
  cbind(Sepal.Length, Sepal.Width, Petal.Length, Petal.Width)
  ~ Species, data = iris)
```

```
print(summary(fit))
```

	Df	Pillai	approx	F	num	Df	den	Df	Pr(>F)
Species	2	1.1919	53.466	8	290	<	2.2e-16	***	
Residuals	147								

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

O valor-p obtido rejeita a hipótese nula para um nível de significância de 5%. Logo, existem diferenças entre as médias das variáveis estudadas entre as espécies de flor.

## 1.5 Exercício 5.9

Carregamos o conjunto de dados com medidas de 61 ursos do Alaska.

```
M <- matrix(c(3266.46, 1343.97, 731.54, 1175.50, 162.68, 238.37,
              1343.97, 721.91, 324.25, 537.35, 80.17, 117.73,
              731.54, 324.25, 179.28, 281.17, 39.15, 56.80,
              1175.50, 537.35, 281.17, 474.98, 63.73, 94.85,
              162.68, 80.17, 39.15, 63.73, 9.95, 13.88,
              238.37, 117.73, 56.80, 94.85, 13.88, 21.26),
            nrow = 6, ncol = 6, byrow = T)
colnames(M) <- c("Peso", "Comprimento Corporal", "Pescoco",
                "Perímetro", "Comprimento Cabeça", "Largura Cabeça")
mu <- c(95.52, 164.38, 55.69, 93.39, 17.98, 31.13)
n <- 61
p <- 6
```

### 1.5.1 (a) Intervalos de 95% de confiança simultâneos para as seis medidas

```
# Intervalos simulatânea de 95% de confiança

crit <- qf(0.05, p, n - p, lower.tail = F)
# Máximo erro
E <- sqrt((n-1)*p*crit/(n-p))* sqrt(diag(M)/n)
# intervals
LI = mu - E
LS = mu + E

Res=cbind(mu, LI, LS)
colnames(Res)=c("D_bar", "LI", "LS")
print(Res, digits = 3, type = "org")
```

	D_bar	LI	LS
[1,]	95.5	67.3	123.7
[2,]	164.4	151.1	177.6
[3,]	55.7	49.1	62.3
[4,]	93.4	82.6	104.1
[5,]	18.0	16.4	19.5
[6,]	31.1	28.9	33.4

### 1.5.2 (c) Intervalos de 95% de confiança de Bonferroni simultâneos para as seis medidas

```
#####
# Intervalos de 95% de confiança de Bonferroni
#####
```

```
crit <- qt(0.05/(2*4), n-1, lower.tail = F)
# Máximo erro
E <- crit* sqrt(diag(M)/n)
# intervals
LI = mu - E
LS = mu + E
```

```
Res=cbind(mu, LI, LS)
colnames(Res)=c("D_bar", "LI", "LS")
print(Res,digits=3, type = "org")
```

	D_bar	LI	LS
[1,]	95.5	76.7	114.4
[2,]	164.4	155.5	173.2
[3,]	55.7	51.3	60.1
[4,]	93.4	86.2	100.6
[5,]	18.0	16.9	19.0
[6,]	31.1	29.6	32.7